

1. 硬體規格

- 筆電
 - CPU : Intel(R) Core(TM) i7-10510U CPU @ 1.60GHz (8核)
 - 顯卡 : NVIDIA GeForce MX250
 - RAM : 12GB
- 桌電
 - CPU : Intel(R) Core(TM) i7-4790 CPU @ 3.60GHz (8核)
 - 顯卡 : NVIDIA GeForce GTX 1060 3GB
 - RAM : 16GB

桌電大概七年前買的，顯卡後來有更新過，筆電是兩年前買的。作業系統皆為 Windows10，沒有其他規格的電腦可以選了，如果筆電顯卡跑不動實驗，會讓桌機去跑。

電話：0901228989

2.

source code:

```
1  from numpy import *
2  import matplotlib.pyplot as plt
3  train_in = array([[0,2,0],[0,0,1],[0,1,1],[1,0,1],[1,1,1]])
4  train_sol = array([[0,0,0,1,1]]).T
5
6  # Initialize nn_weights
7  random.seed(1)
8  nn_weights = 2 * random.random((3, 1)) - 1
9
10 # Initialize the error array to draw the figure
11 error_points = []
12
13 # learning rate and epoch initialize
14 learning_rate = 1.0
15 epoch = 200
16
17 # Unknown test input
18 test_in = array([1,0,0])
19
20 # Train the network
21 for i in range(epoch):
22     print("\n i= ", i, "nn_weight=")
23     print(nn_weights)
24
25     # calculate the outputs for each training examples
26     train_out = 1 / (1 + exp(-(dot(train_in, nn_weights))))
27     print("train_out =")
28     print(train_out)
29
30     # calculate error
31     error = 1.0 - (1/(1 + exp(-(dot(test_in, nn_weights)))))
32     error_points.append(error)
33
```



```


34     # Run the NN adjustments
35     nn_weights += learning_rate * dot(train_in.T, (train_sol-
train_out)*train_out*(1-train_out))
36
37     # draw figure
38     plt.plot(error_points)
39     plt.ylim(0.0, 0.6)
40     plt.title("learning rate = " + str(learning_rate) + ", epoch = " +
str(epoch))
41     plt.xlabel("generation")
42     plt.ylabel("total error")
43     plt.show()
44
45     # Print the result for our unknown test input
46     print('\nThe final prediction is ',1/(1 + exp(-(dot(test_in, nn_weights)))))

```



result figure:


- 200 epoch vs. 500 epoch vs. 1000 epoch (learning rate = 1.0)





- learning rate 0.3 vs. 1.0 vs. 1.5 (200 epoch)





增加 epoch 的數量後，誤差會越來越接近 0 但不為 0。learning rate 會影響整個學習的速度，雖然最後學習的成果差不多。

3.

L1 和 L2 正規化是為了讓訓練過程中，不要有某些特徵太過於突出，導致帶偏了整個訓練的方向，或是某個特徵權重太高，後面改不回來，也就是所謂的「Overfitting」。

$$L1: ||w||_1 = \sum_{j=1}^m |w_j|$$

L1 正規化會將模型裡所有的參數都取絕對值，經過運算後將過於複雜的模型簡化，也就是有辦法將沒有用的權重設為 0，留下訓練模型認為重要的權重，讓整個模型稀疏。

$$L2: ||w||^2 = \sum_{j=1}^m w_j^2$$

L2 正規化會將模型裡所有的參數都取平方和，在經過運算後一樣可以簡化模型。但只會進行削弱權重，使所有神經元都處於活動狀態，但所有權重值都保持在較小的狀態。

4.

7 種形狀分別為 $X_1, X_2, X_1^2, X_2^2, X_1X_2, \sin(X_1), \sin(X_2)$ ，藍色為正，橘色為負。在測試四種分類資料時，每個都有其運用之處。


X_1^2 和 X_2^2 的組合可以在視覺化的資料中產生類似圓形的圖案； $\sin(X_1)$ 和 $\sin(X_2)$ 可以讓資料分段出現，而不是連續出現，在螺旋狀訓練時可以用到； X_1X_2 的向量甚至可以直接用來訓練第二種圖形； X_1, X_2 則可以簡單的讓訓練神經有上和下、左和右的概念。

5.

迴歸模型在機器學習裡，也就是特徵與目標的關係。透過梯度下降去找出成本函數算出來最低誤差值的最佳迴歸模型。像我們在 TensorFlow Playground 試著訓練的就是最佳的迴歸模型，找出每種形狀與目標的關係權重。


6.

- Tanh：雙曲正切函數




在訓練所有的問題都有不錯的表現，略遜於 ReLU。

- Linear :




除了螺旋狀的問題，都可以很快跑出結果，螺旋狀問題我自己沒有成功跑出來，幾乎沒有反應。

- ReLU：線性整流函式



可以成功訓練出所有問題的解，速度也相當快速，能有效克服梯度消失的問題。

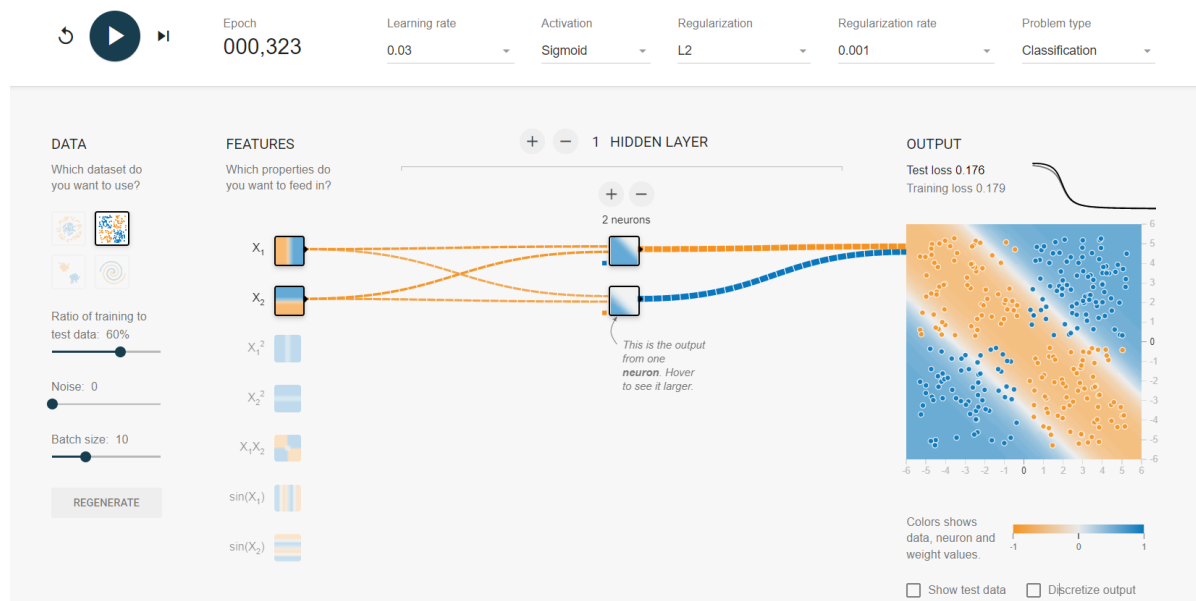
- Sigmoid : 二焦點曲線函數

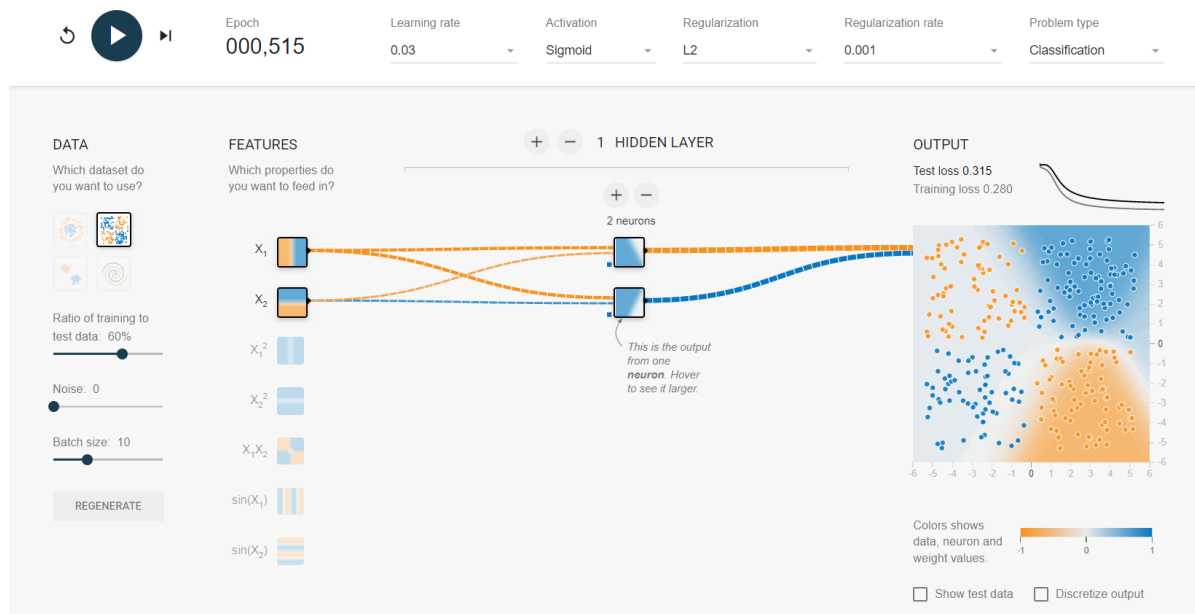
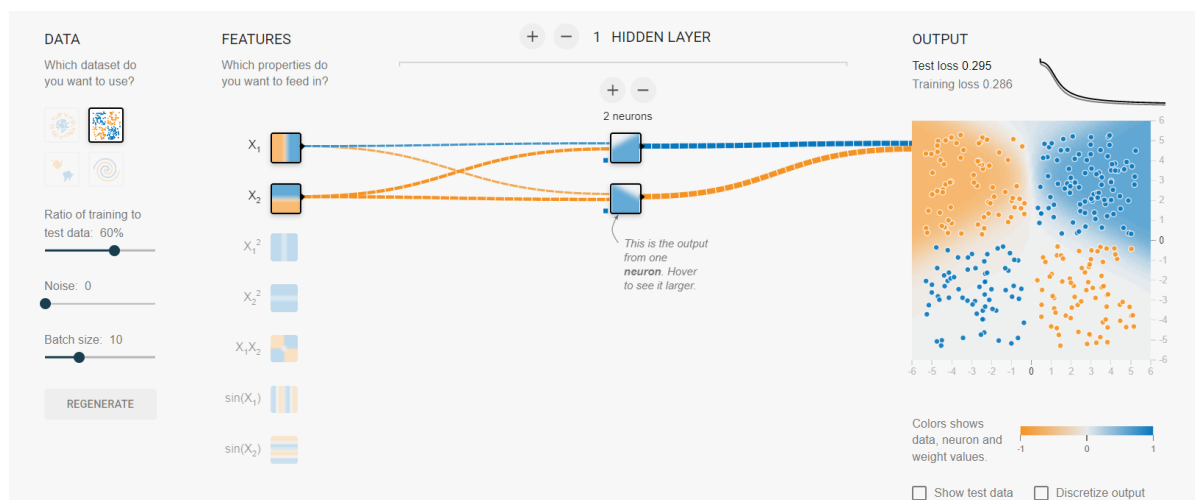
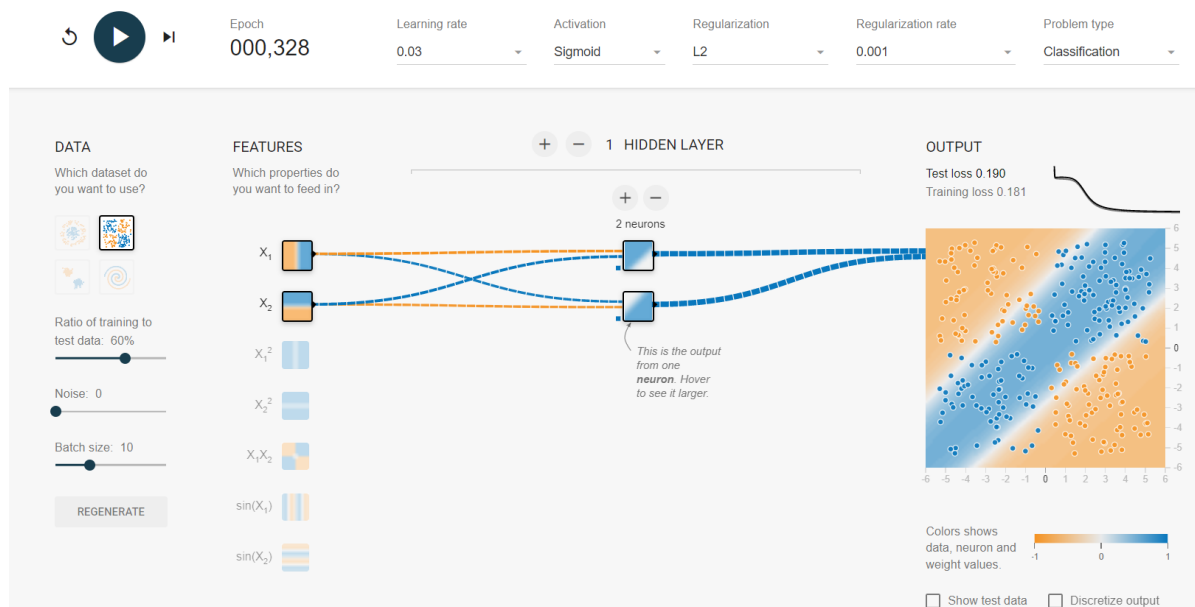


能夠成功訓練四種問題，和 \tanh 速度差不多。

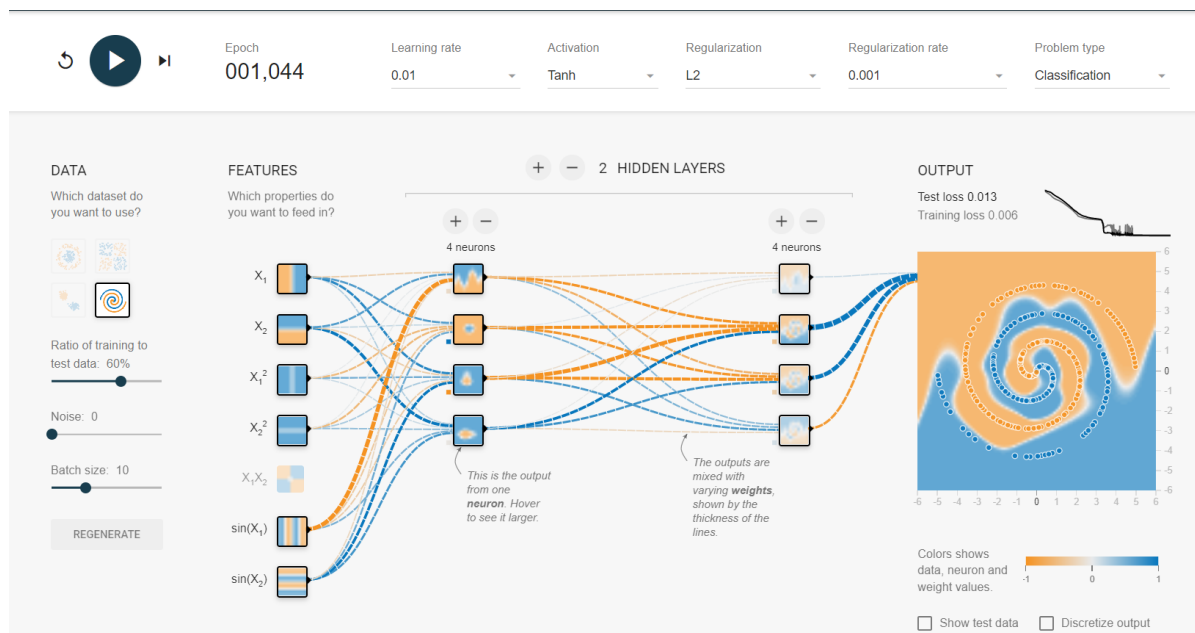
7.

如果只用 X_1, X_2 的話，這是個沒有辦法得到解答的問題，並且會訓練出幾種結果：



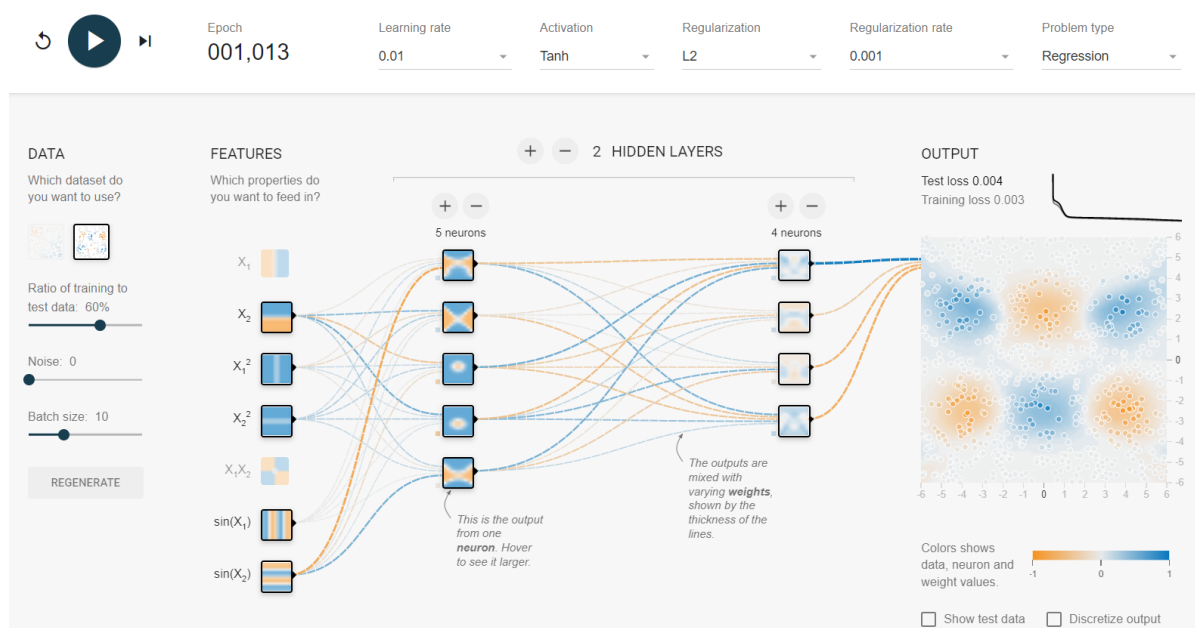


8.



從原本全部加滿，慢慢刪減，試著用最少的 layers 和 neurons，正確率參考他右上角的 Training loss。大概花了一個小時在玩這個圖形訓練，我覺得已經算滿意了。

9.



試了幾次就得到了還不錯的結果，正確率一樣參考他算的 Training loss。整個訓練和測試過程大概10分鐘。

10.

在跑上面兩個訓練的時候，都是使用 Tahn 的 activation function，不過後來回去寫第六題並試著找出差異的時候，發現 ReLU 的表現普遍比較好，在 Regression 訓練沒有 Tahn 快，但在 Classification 的速度就比較快。而 Linear 則是沒辦法訓練出螺旋狀的問題，sigmoid 則是和 Tahn 速度差不多。

11.

L1 和 L2 蠻難解釋的，在找資料時自己先看懂都很困難了。

TensorFlow Playground 裡的 Linear Activation 函數到底是什麼，也找了很久，過程中還一直看到線性回歸和羅吉斯回歸，後來詢問同學後才發現原來只是簡單的 $x = y$ 。

看不太懂第7題想要做什麼。

螺旋狀的分類問題比想像中還難達成，有看到同學曾經比我用更少的 neurons 得到比我還要好的訓練結果。

12.

1. Regularization in Deep Learning – L1, L2, and Dropout : <https://towardsdatascience.com/regularization-in-deep-learning-l1-l2-and-dropout-377e75acc036>
2. Machine Learning — 給自己的機器學習筆記 — Linear Regression — 迴歸模型介紹與公式原理教學 : <https://chwang12341.medium.com/machine-learning-%E7%B5%A6%E8%87%AA%E5%B7%B1%E7%9A%84%E6%A9%9F%E5%99%A8%E5%AD%B8%E7%BF%92%E7%AD%86%E8%A8%98-linear-regression-%E8%BF%B4%E6%AD%B8%E6%A8%A1%E5%9F%8B%E4%BB%8B%E7%B4%B9%E8%88%87%E5%85%AC%E5%BC%8F%E5%8E%9F%E7%90%86%E6%95%99%E5%AD%B8-35e34ad8c690>
3. 深度學習：使用激勵函數的目的、如何選擇激勵函數 Deep Learning: the role of the activation function : <https://mropengate.blogspot.com/2017/02/deep-learning-role-of-activation.html>